
Algorithm 1 다중 공급업체 환경의 인코더-듀얼 디코더 순전파

Require: 상태 S_t (재고, 파이프라인 x_t , 계절성 정보), 파라미터 θ

Ensure: 행동 $C_t = [u_{t,k}, q_{t,k}]$, 행동 확률 $p_\theta(C_t|S_t)$

```
1: 1. 인코더 단계 (State Encoding)
2:    $H_{enc} \leftarrow \text{Encoder}(S_t; \theta_{enc})$  ▷ 상태  $S_t$ 의 특징 벡터 추출
3: 2. 듀얼 디코더 단계 (Dual Decoder Step)
4:   Phase 1: 공급업체 선택 (Supplier Selection)
5:     ▷  $K$ 개의 공급업체 + '주문 안 함(Null)'을 포함한  $K + 1$  차원 로짓
6:      $h_{dec}^{(1)} \leftarrow \text{DecoderBlock}_1(H_{enc}; \theta_{dec1})$ 
7:      $\pi(k|S_t) \leftarrow \text{Softmax}(\text{Linear}(h_{dec}^{(1)}))$ 
8:      $k^* \sim \pi(\cdot|S_t)$  ▷ 확률에 따라 공급업체 인덱스  $k^*$  샘플링
9:     선택된  $k^*$ 에 따라 이진 변수 설정
10:    if  $k^* \in \mathcal{K}$  then
11:       $u_{t,k^*} \leftarrow 1, \quad u_{t,k \neq k^*} \leftarrow 0$ 
12:    else ▷ 주문 안 함 선택 시
13:       $u_{t,k} \leftarrow 0 \quad \forall k$ 
14:    end if
15:    Phase 2: 주문 수량 결정 (Order Quantity)
16:    if  $\sum_k u_{t,k} = 1$  then ▷ 특정 공급업체  $k^*$ 가 선택된 경우
17:       $h_{dec}^{(2)} \leftarrow \text{DecoderBlock}_2(H_{enc}, u_{t,k^*}; \theta_{dec2})$ 
18:      정책 분포 파라미터 도출 (최적 주문량에 대한 평균  $\mu$ , 표준편차  $\sigma$ )
19:       $\mu_t, \sigma_t \leftarrow \text{ProjectionHead}(h_{dec}^{(2)})$ 
20:       $q_{t,k^*} \sim \mathcal{N}(\mu_t, \sigma_t)$  ▷ 정규분포  $\mathcal{N}$ 에서 수량 샘플링
21:       $q_{t,k \neq k^*} \leftarrow 0$ 
22:    else
23:       $q_{t,k} \leftarrow 0 \quad \forall k$ 
24:    end if
25: 3. 최종 행동 및 확률 반환
26:    $C_t \leftarrow [u_{t,k}, q_{t,k}]$ 
27:    $p_\theta(C_t|S_t) \leftarrow \pi(k^*|S_t) \cdot p(q_{t,k^*}|k^*, S_t)$ 
28: return  $C_t, p_\theta(C_t|S_t)$ 
```

Algorithm 2 Greedy Rollout Baseline을 활용한 강화 학습

Require: 계획 기간 T , 에폭 E , 배치 B , 공급업체 집합 $\mathcal{K}$

```
1: 정책 네트워크  $\theta$  초기화, 베이스라인  $\theta^{BL} \leftarrow \theta$ 
2: for epoch = 1, ...,  $E$  do
3:   for batch  $i = 1, \dots, B$  do
4:     초기 상태  $S_0$  생성
5:     1. 정책 비교 (Advantage 계산)
6:       a) 샘플링 돌아웃 (Exploration)
7:          $C_{0:T}^{sample}, \text{Cost}^{sample} \leftarrow \text{RunEpisode}(\theta, S_0, \text{mode}='Sample')$ 
8:       b) 그리디 돌아웃 (Baseline)
9:          $C_{0:T}^{greedy}, \text{Cost}^{greedy} \leftarrow \text{RunEpisode}(\theta^{BL}, S_0, \text{mode}='Greedy')$ 
10:      2. 그래디언트 계산
11:         $\text{Advantage} \leftarrow (\text{Cost}^{sample} - \text{Cost}^{greedy})$ 
12:         $\nabla J \leftarrow \frac{1}{B} \sum_{t=0}^T \text{Advantage} \cdot \nabla_{\theta} \log p_{\theta}(C_t^{sample} | S_t)$ 
13:         $\theta \leftarrow \text{Adam}(\theta, \nabla J)$ 
14:      end for
15:      3. 베이스라인 업데이트 검증 (t-test)
16:      if  $\text{Validate}(\theta)$  is significantly better than  $\text{Validate}(\theta^{BL})$  then
17:         $\theta^{BL} \leftarrow \theta$  ▷ 베이스라인 갱신
18:      end if
19:   end for

20: function  $\text{RUNEPISODE}(\theta, S_0, \text{mode})$ 
21:   Total Cost  $L \leftarrow 0$ 
22:   for  $t = 0, \dots, T$  do
23:      $C_t, - \leftarrow \text{Forward}(S_t; \theta, \text{mode})$  ▷ Alg 1 호출
24:     비용 계산 (구매 + 운송 + 재고 + 페널티)
25:      $\text{Cost}_t = \sum_{k \in \mathcal{K}} (P_k q_{t,k} + C_{\text{ship},k} \lceil \frac{q_{t,k}}{C_{\text{cap},k}} \rceil)$ 
26:      $+ h[I_{t+1}]^+ + b[I_{t+1}]^- + \omega[I_{t+1} - CAP]^+$ 
27:      $L \leftarrow L + \text{Cost}_t$ 
28:      $S_{t+1} \leftarrow \text{StateTransition}(S_t, C_t)$  ▷ 식 (2), (3) 적용
29:   end for
30:   return  $C_{0:T}, L$ 
31: end function
```
